

Problemi di Algoritmica 2

Alessandro Ambrosano

Jacopo Notarstefano

Francesco Salvatori

10 dicembre 2012

If you're having girl problems
I feel bad for you son
I got 99 problems
but a bitch ain't one.

Jay-Z

Problema 1

Ordinamento in memoria esterna

Problema. *Nel modello EMM (external memory model), mostrate come implementare il k -way merge, ossia la fusione di n sequenze individualmente ordinate e di lunghezza totale N , con costo I/O di $O(\frac{N}{B})$ dove B è la dimensione del blocco. Minimizzare e valutare il costo di CPU. Analizzare il costo del merge (I/O complexity, CPU complexity) che utilizza tale k -way merge.*

Problema 2

Limite inferiore per la permutazione

Problema. *Estendere l'argomentazione usata per il limite inferiore del problema dell'ordinamento in memoria esterna a quello della permutazione: dati N elementi e_1, e_2, \dots, e_N e un array π contenente una permutazione degli interi in $[1, 2, \dots, N]$, disporre gli elementi secondo la permutazione in π . Dopo tale operazione, la memoria esterna deve contenerli nell'ordine $e_{\pi[1]}, e_{\pi[2]}, \dots, e_{\pi[N]}$.*

Mostreremo che il problema presenta un lower-bound di $\Omega\left(\min\left\{N, \frac{N}{B} \log_{\frac{M}{B}} \frac{N}{B}\right\}\right)$. L'idea è la seguente: consideriamo una sequenza di t operazioni di input, e contiamo quante permutazioni diverse possiamo ottenere. Trovando il minimo t che ci garantisce la possibilità di ottenere *tutte* le permutazioni distinte avremo allora il lower-bound desiderato.

Consideriamo una generica operazione di input: possiamo scegliere tra N pagine in memoria (in realtà, se gli elementi sono disposti in modo contiguo, la scelta si restringe a $\frac{N}{B} \leq N$, ma è corretto usare N perché stiamo cercando una sottostima del numero di I/O necessari, e dunque una sovrastima del numero di permutazioni ottenibili data una sequenza di I/O di lunghezza fissata). Distinguiamo ora due casi:

- Se la pagina che ho scelto viene caricata in memoria per la prima volta (e questo avviene $\binom{N}{B}$ volte), posso permutare i suoi elementi in $B!$ modi, e disporli tra gli elementi già in memoria in al più $\binom{M}{B}$ modi.
- Se la pagina era già stata caricata in memoria in precedenza, i suoi elementi sono già permutati nell'ordine desiderato, dunque devo solo scegliere gli $\binom{M}{B}$ modi in cui disporli rispetto agli elementi già in memoria.

Unendo i due casi, dopo una sequenza di t I/O posso produrre al più

$$N^t \cdot (B!)^{\frac{N}{B}} \cdot \left(\binom{M}{B}\right)^t$$

permutazioni distinte; ovviamente vogliamo che questo numero risulti maggiore di $N!$. Passando ai logaritmi, dev'essere

$$t \log N + \frac{N}{B} \log B! + t \log \left(\binom{M}{B}\right) \geq \log N!,$$

da cui, usando le approssimazioni $\log x! \sim x \log x$ e $\log \binom{n}{k} \sim k \log \frac{n}{k}$,

$$t \log N + N \log B + tB \log \frac{M}{B} \geq N \log N$$

$$t \left(\log N + B \log \frac{M}{B} \right) \geq N(\log N - \log B)$$

$$t \geq \frac{N \log \frac{N}{B}}{\log N + B \log \frac{M}{B}}$$

Distinguiamo ancora due casi:

- Se $\log N \leq B \log \frac{M}{B}$ dev'essere

$$t \geq \frac{N \log \frac{N}{B}}{2B \log \frac{M}{B}} = \Omega \left(\frac{N}{B} \log \frac{M}{B} \frac{N}{B} \right).$$

- Se invece $\log N \geq B \log \frac{M}{B}$ allora

$$t \geq \frac{N \log \frac{N}{B}}{2 \log N} \geq \frac{N \log N - N \log B}{2 \log N} =$$

$$= \frac{1}{2} \left(N - N \frac{\log B}{\log N} \right) \geq \frac{1}{2} \left(N - \frac{1}{2} N \right) = \Omega(N),$$

il che ovviamente vale purché $\frac{\log B}{\log N} \leq \frac{1}{2}$, ossia $B \leq \sqrt{N}$, relazione vera in tutti i casi di interesse.

Dall'unione dei due casi segue il lower-bound desiderato.

Problema 3

Permutazione in memoria esterna

Problema. *Dati due array A e C di N elementi, dove A è l'input e C una permutazione di $\{0, 1, \dots, n-1\}$, descrivere e analizzare nel modello EMM un algoritmo ottimo per costruire $A[C[i]]$ per $0 \leq i \leq n-1$.*

Problema 4

Multi-selezione in memoria esterna

Problema. *Scrivere tutti i passaggi dell'analisi del costo e della correttezza dell'algoritmo di multi-selezione visto a lezione.*

Vogliamo esibire un algoritmo che selezioni un certo numero di pivot da un insieme S di cardinalità N in modo tale che la distanza fra pivot consecutivi sia piccola. Il nostro scopo sarà usare questo algoritmo per costruire un analogo del QUICKSORT in memoria esterna, così come la k -way merge ci ha permesso di costruire l'algoritmo di MERGE SORT in memoria esterna.

Ci potremmo aspettare di dover trovare m pivot, in analogia a quanto facciamo per la Merge. In realtà è sufficiente determinarne \sqrt{m} . Diamo di seguito l'algoritmo e due lemmi. Nel primo dimostreremo il costo lineare, nel secondo la correttezza dell'algoritmo.

Algoritmo 1 Multi-selezione in memoria esterna

- 1: Carico e ordino in memoria principale $\frac{N}{M}$ run di M elementi ciascuno.
 - 2: Da ogni run seleziono un elemento ogni $\frac{\sqrt{m}}{4}$ e chiamo G (elementi verdi) l'insieme degli elementi selezionati.
 - 3: Uso l'algoritmo dei cinque autori \sqrt{m} volte per selezionare in G un elemento ogni $\frac{4N}{m}$ e chiamo R (elementi rossi) l'insieme degli elementi selezionati.
 - 4: Ritorno R .
-

Lemma 1 (Costo). *L'algoritmo compie $O(n)$ I/O.*

Dimostrazione. *La prima riga dell'algoritmo comporta soltanto di scandire tutti gli elementi: l'ordinamento di ogni run viene infatti svolto in memoria principale, e non comporta ulteriori I/O. Anche la seconda riga consiste in una scansione di tutti gli elementi. Per stimare il numero di I/O della terza riga sfruttiamo invece il fatto che ogni esecuzione dell'algoritmo dei cinque autori comporta una scansione di tutti gli elementi. Abbiamo dunque \sqrt{m} scansioni di $|G|$ elementi, perciò:*

$$\sqrt{m} \cdot O\left(\frac{|G|}{B}\right) = \sqrt{m} \cdot O\left(\frac{4N}{B\sqrt{m}}\right) = O\left(\frac{4N}{B}\right) = O(n),$$

dove la prima eguaglianza discende dal fatto che, avendo selezionato un elemento ogni $\frac{\sqrt{m}}{4}$, la cardinalità di G è $\frac{4N}{\sqrt{m}}$. Ogni riga contribuisce quindi $O(n)$ I/O, da cui la tesi.



Figura 4.1: Ogni riga orizzontale rappresenta un run ordinato, e i cerchietti gli elementi di ogni run. Cerchietti rossi e verdi rappresentano rispettivamente gli elementi di R e G , cerchietti neri i restanti elementi senza colore. Sono inoltre raffigurati in giallo i bordi definiti dalla posizione degli elementi rossi nei quali possiamo avere elementi senza colore compresi fra un rosso e un verde.

Lemma 2 (Correttezza). *Il numero di elementi di S compresi fra due elementi di R è minore di $\frac{3}{2} \frac{N}{\sqrt{m}}$.*

Dimostrazione. *Vogliamo dunque stimare il numero di elementi di S compresi fra due generici elementi rossi r_1 e r_2 . Possiamo dividerli in tre categorie:*

- *Gli elementi verdi compresi fra i due elementi rossi r_1 e r_2 .*
- *Gli elementi senza colore compresi fra due elementi verdi.*
- *Gli elementi senza colore compresi fra un rosso e un verde.*

I primi sono facilmente maggiorati da $X = \frac{4N}{m}$: nella terza riga dell'algoritmo abbiamo infatti scelto un rosso ogni $\frac{4N}{m}$ elementi verdi.

I secondi sono invece maggiorati da $Y = \frac{N}{\sqrt{m}} - \frac{4N}{m}$. Per la seconda riga dell'algoritmo abbiamo infatti $\frac{\sqrt{m}}{4} - 1$ elementi senza colore fra due verdi consecutivi appartenenti allo stesso run, avendo scelto un verde ogni $\frac{\sqrt{m}}{4}$ elementi. Per la terza riga abbiamo al più $\frac{4N}{m}$ elementi verdi fra r_1 e r_2 , dunque al più $\frac{4N}{m}$ coppie di elementi verdi consecutivi nello stesso run. Ma allora il numero cercato è stimato dal prodotto, e quindi da:

$$\frac{4N}{m} \left(\frac{\sqrt{m}}{4} - 1 \right) = \frac{N}{\sqrt{m}} - \frac{4N}{m}.$$

I terzi sono invece maggiorati da $Z = \frac{n}{2\sqrt{m}} - \frac{2n}{m}$. Per vedere questo abbiamo bisogno della figura. Osserviamo infatti che la posizione dei due elementi rossi definisce un paio di "bordi" (raffigurati in giallo in figura) in cui è possibile trovare gli elementi del terzo tipo. Ognuno di questi bordi può contenere al più $\frac{\sqrt{m}}{4} - 1$ elementi, perché se ne contenesse di più conterrebbe sicuramente due verdi, quindi elementi compresi fra due verdi. Per ognuno degli $\frac{N}{M}$ run abbiamo insomma 2 bordi contenenti al più $\frac{\sqrt{m}}{4} - 1$ elementi, perciò possiamo stimare il numero di elementi del terzo tipo con il loro prodotto, cioè:

$$2 \cdot \frac{n}{m} \cdot \left(\frac{\sqrt{m}}{4} - 1 \right) = \frac{n}{2\sqrt{m}} - \frac{2n}{m},$$

dove abbiamo usato che $\frac{N}{M} = \frac{n}{m}$ essendo $n = \frac{N}{B}$ e $m = \frac{M}{B}$.

Di conseguenza il numero totale degli elementi compresi fra r_1 e r_2 è maggiorato da:

$$\begin{aligned} X + Y + Z &= \frac{4N}{m} + \frac{N}{\sqrt{m}} - \frac{4N}{m} + \frac{n}{2\sqrt{m}} - \frac{2n}{m} \\ &\leq \frac{N}{\sqrt{m}} + \frac{n}{2\sqrt{m}} \end{aligned}$$

nella quale abbiamo cancellato i termini uguali di segno opposto e un termine negativo, ottenendo un'ulteriore maggiorazione. Abbiamo inoltre:

$$\begin{aligned} \frac{N}{\sqrt{m}} + \frac{n}{2\sqrt{m}} &\leq \frac{N}{\sqrt{m}} + \frac{N}{2\sqrt{m}} \\ &= \frac{3}{2} \frac{N}{\sqrt{m}} \end{aligned}$$

essendo $n = \frac{N}{B}$, da cui la tesi.

Problema 5

MapReduce

Problema. *Utilizzare il paradigma Scan & Sort mediante la MapReduce per calcolare la distribuzione dei gradi in ingresso delle pagine Web. In particolare, specificare quanti passi di tipo MapReduce sono necessari e quali sono le funzioni Map e Reduce impiegate. Ipotizzare di avere già tali pagine a disposizione.*

Problema 6

Navigazione implicita in vEB

Problema. *Dato un albero completo memorizzato secondo il layout di van Emde Boas (vEB) in modo implicito, ossia senza l'ausilio di puntatori (come succede nello heap binario implicito), trovare la regola per navigare in tale albero senza usare puntatori espliciti.*

Problema 7

Layout di alberi binari

Problema. *Proporre una paginazione di alberi binari in blocchi di dimensione B per realizzare un loro layout in memoria esterna: valutare se un qualunque cammino minimo radice-nodo di lunghezza l attraversa sempre $O(\frac{l}{\log B})$ pagine. NOTA: per chi vuole, esiste una versione più impegnativa di questo esercizio, basta contattarmi per averla.*

Problema 8

Suffix array in memoria esterna

Problema. *Utilizzando la costruzione del suffix array basata sul MERGE SORT e la tecnica DC3 vista a lezione, progettare un algoritmo per EMM per costruire il suffix array di un testo che abbia la stessa complessità del MERGE SORT in EMM.*

Problema 9

Famiglia di funzioni hash uniformi

Problema. *Mostrare che la famiglia di funzioni hash $H = \{h(x) = ((ax + b) \bmod p) \bmod m\}$ è (quasi) uniforme, dove $a, b \in [m]$ con $a \neq 0$ e p è un numero primo sufficientemente grande.*

Siano $k \neq l$ due chiavi, $h \in H$ e $r = ak + b \pmod{p}$, $s = al + b \pmod{p}$. Abbiamo che $r - s = a(k - l) \pmod{p}$ da cui, essendo $a \neq 0$ e, per p sufficientemente grande, $(k - l) \not\equiv 0 \pmod{p}$, segue che $r - s \not\equiv 0$.

È dunque possibile una collisione tra gli hash delle due chiavi se e solo se $r \pmod{m} = s \pmod{m}$.

Notiamo che per a sono possibili $p - 1$ valori (lo 0 non va bene) mentre per b ve ne sono p : in tutto abbiamo $p(p - 1)$ possibili coppie (a, b) ; ma anche per (r, s) vi sono $p(p - 1)$ possibilità (fissato r , per s vanno bene tutti i valori tranne quello assunto da r): segue che le coppie (a, b) e le coppie (r, s) possono essere messe in corrispondenza biunivoca. Inoltre se la coppia (a, b) è scelta a caso con probabilità uniforme ciascuna coppia (r, s) ha la stessa probabilità di essere l'immagine di due date chiavi l e k . Questo significa che

$$\Pr[h(k) = h(l)] = \Pr[r = s \pmod{m}].$$

Fissiamo r : i possibili valori per s che originano una collisione sono al più

$$\left\lceil \frac{p}{m} \right\rceil - 1 \leq \frac{p + m - 1}{m} - 1 = \frac{p - 1}{m}.$$

Da questo segue che

$$\Pr[r = s \pmod{m}] \leq \frac{\frac{p-1}{m}}{p-1} = \frac{1}{m},$$

il che significa

$$\Pr[h(k) = h(l)] \leq \frac{1}{m},$$

come volevasi dimostrare.

Problema 10

Count-min sketch: estensione

Problema. *Estendere l'analisi vista a lezione permettendo di incrementare e decrementare i contatori con valori arbitrari.*

Lemma 3 (Approssimazione). *Per il count min sketch a valori arbitrari vale:*

$$Pr \left[F[i] - 3\varepsilon \|F\| \leq \tilde{F}[i] \leq F[i] + 3\varepsilon \|F\| \right] \geq 1 - \delta^{\frac{1}{4}}$$

con $\tilde{F}[i] = \text{median}_j \{T[j, h_j(i)]\}$.

Dimostrazione. *Osserviamo innanzi tutto che $\tilde{F}[i] = T[\hat{i}, h_{\hat{i}}(i)]$ per qualche \hat{i} , e vale*

$$\tilde{F}[i] = F[i] + \sum_{k=1}^n I_{\hat{i},k} F[k]$$

dove $I_{j,i,k}$ è la variabile indicatrice così definita:

$$I_{j,i,k} = \begin{cases} 1 & \text{se } i \neq k \wedge h_j(i) = h_j(k) \\ 0 & \text{altrimenti} \end{cases}$$

Ponendo $X_{j,i} = \sum_{k=1}^n I_{j,i,k} F[k]$ abbiamo:

$$\begin{aligned} & Pr \left[F[i] - 3\varepsilon \|F\| \leq \tilde{F}[i] \leq F[i] + 3\varepsilon \|F\| \right] \\ &= Pr \left[F[i] - 3\varepsilon \|F\| \leq F[i] + \sum_{k=1}^n I_{\hat{i},k} F[k] \leq F[i] + 3\varepsilon \|F\| \right] \\ &= Pr \left[F[i] - 3\varepsilon \|F\| \leq F[i] + X_{\hat{i},i} \leq F[i] + 3\varepsilon \|F\| \right] \\ &= Pr \left[-3\varepsilon \|F\| \leq X_{\hat{i},i} \leq 3\varepsilon \|F\| \right] \\ &= Pr \left[|X_{\hat{i},i}| \leq 3\varepsilon \|F\| \right] \end{aligned}$$

$$\begin{aligned}
E[I_{j,i,k}] &= Pr[i \neq k \wedge h_j(i) = h_j(k)] \\
&= Pr[\cup_{a=1}^c i \neq k \wedge h_j(i) = a \wedge h_j(k) = a] \\
&= \sum_{a=1}^c Pr[i \neq k \wedge h_j(i) = a \wedge h_j(k) = a] \\
&= \sum_{a=1}^c Pr[h_j(i) = a] Pr[i \neq k \wedge h_j(k) = a] \\
&= \frac{c}{c^2} = \frac{1}{c} = \frac{\varepsilon}{e}
\end{aligned}$$

da cui

$$\begin{aligned}
E[|X_{j,i}|] &= E\left[\left|\sum_{k=1}^n I_{j,i,k} F[k]\right|\right] \\
&\leq \sum_{k=1}^n E[|I_{j,i,k}|] |F[k]| \\
&= \frac{\varepsilon}{e} \sum_{k=1}^n |F[k]| \\
&= \frac{\varepsilon}{e} \|F\|
\end{aligned}$$

e quindi per ogni j , usando la disuguaglianza di Markov

$$Pr[|X_{j,i}| \geq 3\varepsilon \|F\|] \leq \frac{E[|X_{j,i}|]}{3\varepsilon \|F\|} = \frac{\frac{\varepsilon}{e} \|F\|}{3\varepsilon \|F\|} = \frac{1}{3e} < \frac{1}{8}$$

Notiamo che perché valga $|X_{j,i}| \geq 3\varepsilon \|F\|$, deve valere $|X_{j,i}| \geq 3\varepsilon \|F\|$, per questo scopo introduciamo le seguenti variabili casuali:

$$Y_j = \begin{cases} 1 & \text{se } |X_{j,i}| \geq 3\varepsilon \|F\| \\ 0 & \text{altrimenti} \end{cases}$$

Se poniamo $p = E[Y_j] = Pr[|X_{j,i}| \geq 3\varepsilon \|F\|]$, e $Y = Y_1 + \dots + Y_r$, abbiamo $E[Y] = rp$. Noi vogliamo $Y \Rightarrow \frac{r}{2}$, per calcolarne la probabilità dobbiamo introdurre la disuguaglianza di Chernoff.

Definizione (Chernoff bound). Se X_1, \dots, X_n sono n prove di Poisson indipendenti, identicamente distribuite, ossia $\forall i. P[X_i = 1] = p, P[X_i = 0] = 1 - p$, se prendiamo $X = \sum_{i=1}^n X_i$ e $\mu = E[X]$, per ogni $\lambda > 0$ si ha:

$$Pr[X \geq (1 + \lambda)\mu] < \left(\frac{e^\lambda}{(1 + \lambda)^{1+\lambda}} \right)^\mu$$

Quindi ponendo $\mu = E[Y] = rp$, $(1 + \lambda)\mu = \frac{r}{2} \Rightarrow 1 + \lambda = \frac{1}{2p}$, abbiamo

$$\begin{aligned} Pr[Y > \frac{r}{2}] &< \left(\frac{e^\lambda}{(1 + \lambda)^{1+\lambda}} \right)^\mu \\ &= \frac{1}{e^\mu} \left(\frac{e}{1 + \lambda} \right)^{(1+\lambda)\mu} \\ &= \frac{1}{e^{rp}} \left(\frac{e}{\frac{1}{2p}} \right)^{\frac{r}{2}} \\ &= \frac{1}{e^{rp}} (2pe)^{\frac{r}{2}} \end{aligned}$$

Quindi se $\frac{1}{e^{rp}} (2pe)^{\frac{r}{2}} \leq \frac{1}{2^{\frac{r}{2}}} (= \delta^{\frac{1}{4}})$ abbiamo concluso:

$$\begin{aligned} \frac{1}{e^{rp}} (2pe)^{\frac{r}{2}} &\leq \frac{1}{2^{\frac{r}{2}}} \\ 2^{\frac{r}{4}} &\leq e^{rp} \frac{1}{(2pe)^{\frac{r}{2}}} \\ &\{e^{rp} \geq 1, \text{ quindi è sufficiente mostrare quanto sotto}\} \\ 2^{\frac{r}{4}} &\leq \frac{1}{(2pe)^{\frac{r}{2}}} \\ 2^{\frac{1}{2}} &\leq \frac{1}{2pe} \\ p &\leq \frac{1}{2\sqrt{2}e} \end{aligned}$$

che vale in quanto $2\sqrt{2}e \sim 7.668$ e $p < \frac{1}{8}$. □

Problema 11

Count-min sketch: prodotto scalare

Problema. *Mostrare come utilizzare il paradigma del count-min sketch per approssimare il prodotto scalare (i.e., approssimare $\sum_{k=1}^n F_a[k] \cdot F_b[k]$).*

Lemma 4 (Approssimazione). *Per il prodotto scalare, con valori non negativi per F_a e F_b valgono*

- $a \cdot b \leq a \tilde{\cdot} b$
- $Pr[a \tilde{\cdot} b \leq a \cdot b + \varepsilon ||a|| ||b||] \geq 1 - \delta$

$$\text{con } a \tilde{\cdot} b = \min_j \left\{ \sum_{i=1}^c T_a[j, h_j(i)] T_b[j, h_j(i)] \right\}.$$

Dimostrazione. *Osserviamo innanzi tutto che per un certo \hat{i} vale*

$$a \tilde{\cdot} b = \sum_{i=1}^c T_a[\hat{i}, h_{\hat{i}}(i)] T_b[\hat{i}, h_{\hat{i}}(i)]$$

e se definiamo la variabile $I_{j,i,k}$ come

$$I_{j,i,k} = \begin{cases} 1 & \text{se } i \neq k \wedge h_j(i) = h_j(k) \\ 0 & \text{altrimenti} \end{cases}$$

otteniamo la seguente uguaglianza:

$$a \tilde{\cdot} b = a \cdot b + \sum_{p,q} I_{\hat{i},p,q} F_a[p] F_b[q]$$

- *Non vale ridere perché ho scritto fap*
- *Non vale tornare indietro per leggere se l'ho scritto davvero*

pertanto, vista la non negatività degli elementi di F_a e F_b la prima disuguaglianza vale banalmente.

Per la seconda, ragioniamo col complementare e cerchiamo di calcolare

$$Pr[a \tilde{\cdot} b \geq a \cdot b + \varepsilon ||a|| ||b||]$$

Che, se poniamo $X_{j,i} = \sum_{p,q} I_{j,p,q} F_a[p] F_b[q]$ equivale a calcolare

$$Pr[X_{\hat{i},i} \geq \varepsilon ||a|| ||b||]$$

Per poterla calcolare ci servono innanzi tutto le speranze di $E[I_{j,i,k}]$ e $E[X_{j,i}]$, date da:

$$\begin{aligned} E[I_{j,i,k}] &= Pr[i \neq k \wedge h_j(i) = h_j(k)] \\ &= Pr[\cup_{a=1}^c i \neq k \wedge h_j(i) = a \wedge h_j(k) = a] \\ &= \sum_{a=1}^c Pr[i \neq k \wedge h_j(i) = a \wedge h_j(k) = a] \\ &= \sum_{a=1}^c Pr[h_j(i) = a] Pr[i \neq k \wedge h_j(k) = a] \\ &= \frac{c}{c^2} = \frac{1}{c} = \frac{\varepsilon}{e} \end{aligned}$$

$$\begin{aligned} E[X_{j,i}] &= E[\sum_{i,k} I_{j,i,k} F_a[i] F_b[k]] \\ &= \sum_{i,k} E[I_{j,i,k}] F_a[i] F_b[k] \\ &= \frac{\varepsilon}{e} \sum_{i,k} F_a[i] F_b[k] \\ &\leq \frac{\varepsilon}{e} ||a|| ||b|| \end{aligned}$$

Si ha quindi, per la disuguaglianza di Markov:

$$\begin{aligned} Pr[X_{j,i} \geq \varepsilon ||a|| ||b||] &\leq \frac{E[X_{j,i}]}{\varepsilon ||a|| ||b||} \\ &= \frac{\frac{\varepsilon}{e} ||a|| ||b||}{\varepsilon ||a|| ||b||} \\ &= \frac{1}{e} < \frac{1}{2} \end{aligned}$$

Osserviamo che affinché valga $X_{\hat{i},i} \geq \varepsilon ||a|| ||b||$, è necessario che valga per tutte le r $X_{j,i}$, in quanto $X_{\hat{i},i}$ è la minima tra queste, trattandosi le $X_{j,i}$ di variabili casuali indipendenti, abbiamo che:

$$Pr[X_{\hat{i},i} \geq \varepsilon ||a|| ||b||] < \frac{1}{2^r} = \delta,$$

da cui

$$Pr[X_{\hat{i},i} \leq \varepsilon ||a|| ||b||] \geq 1 - \delta.$$

□

Problema 12

Count-min sketch: interval query

Problema. *Mostrare come utilizzare il paradigma del count-min sketch per rispondere alle interval query (i.e., approssimare $\sum_{k=i}^j F[k]$).*

Per risolvere questo problema suddividiamo ogni range in modo canonico in sottorange di dimensione 2^k , e usiamo $\log n$ count min sketch per memorizzare separatamente i sottorange di dimensione diversa.

La suddivisione avviene in intervalli di tipo $[x2^k + 1, (x + 1)2^k]$ (*diadici*) per $k \in [0, \log n - 1]$, e ogni volta che ci arriva un dato andiamo ad incrementare tutti i count min sketch negli intervalli corrispondenti.

Lemma 5 (Suddivisione canonica). *Qualunque intervallo può essere suddiviso in al più $2 \log n$ intervalli diadici.*

Dimostrazione. *Sia $[l^*, r^*]$ l'intervallo diadico più grande che può stare dentro il nostro intervallo $[l, r]$. Evidentemente vale $||[l^*, r^*]| < n$ e quindi l'intervallo diadico è al più della forma $[x2^{\log n - 1} + 1, (x + 1)2^{\log n - 1}]$, cioè $k < \log n$.*

Consideriamo i due intervalli indotti $[l, x2^k + 1]$ e $[(x + 1)2^k, r]$, ci sono due casi possibili:

- *uno dei due ha dimensione $\geq 2^k$, questo non è un assurdo perché i due intervalli di dimensione 2^k potrebbero essere spostati di 2^k rispetto all'intervallo diadico canonico più vicino di dimensione 2^{k+1} .*

In questo caso ci limitiamo a togliere l'intervallo di dimensione 2^k o dal fondo del primo intervallo indotto o dall'inizio del secondo (è semplice immaginare perché si deve trovare proprio lì), e ci riconduciamo al secondo caso.

- *entrambi gli intervalli indotti hanno dimensione $< 2^k$, questo vuol dire che ogni intervallo indotto può contenere al più un intervallo di dimensione 2^{k-1} , altrimenti sarebbe di dimensione 2^k e quindi assurdo. Inoltre l'intervallo di dimensione 2^{k-1} può essere solo in fondo al primo intervallo o in testa al secondo (altrimenti potrebbero essercene due). Quindi nel caso non si trovasse nessun intervallo di dimensione 2^{k-1} contenuto vorrebbe dire che lo stesso intervallo indotto ha dimensione $< 2^{k-1}$, quindi ripetiamo l'osservazione con $k - 2$, e così via.*

Il numero totale di intervalli è quindi dato da $2 \log n$, in quanto per k_{\max} ce n'è al più due, in accordo al primo caso, e per valori di k minori ce ne può essere al più uno

per ogni intervallo indotto, siccome andiamo a togliere sempre dalla testa o dalla coda, siccome $k_{max} < \log n$ abbiamo la tesi.

Lemma 6 (Approssimazione). *Per la range query con valori non negativi valgono le seguenti proprietà:*

- $\mathcal{Q}(l, r) \leq \tilde{\mathcal{Q}}(l, r)$
- $Pr \left[\tilde{\mathcal{Q}}(l, r) \leq \mathcal{Q}(l, r) + 2\varepsilon \log n \|F\| \right] \geq 1 - \delta.$

Dimostrazione. *Abbiamo*

$$\tilde{\mathcal{Q}}(l, r) = \sum_{k=0}^{\log n - 1} \tilde{\mathcal{Q}}(d_{2^k, i_{k,1}}) + \tilde{\mathcal{Q}}(d_{2^k, i_{k,2}})$$

dove $d_{2^k, i_{k,1}}$ e $d_{2^k, i_{k,2}}$ sono i due intervalli diadici di dimensione 2^k in cui abbiamo scomposto il nostro intervallo $[l, r]$, supponendo per tutti gli intervalli non esistenti di avere $d_{a,b} = []$ e $\mathcal{Q}(d_{a,b}) = 0$.

Inoltre, per ogni intervallo diadico, dalle proprietà dei count min sketch per valori non negativi si ha:

$$\tilde{\mathcal{Q}}(d_{2^k, i}) = \mathcal{Q}(d_{2^k, i}) + \sum_{l=1}^{\frac{n}{2^k}} I_{i,i,l} \mathcal{Q}(d_{2^k, l})$$

da cui segue la prima disuguaglianza.

Per la seconda disuguaglianza abbiamo, ponendo $X_{j,i} = \sum_{l=1}^{\frac{n}{2^k}} I_{i,i,l} \mathcal{Q}(d_{2^k, l})$

$$E[X_{j,i}] \leq \frac{\varepsilon}{e} \|F\|$$

Quindi, su tutti gli intervalli

$$E[\tilde{\mathcal{Q}}(l, r) - \mathcal{Q}(l, r)] \leq 2 \frac{\varepsilon}{e} \log n \|F\|$$

Da cui, per la disuguaglianza di Markov:

$$\begin{aligned} & Pr \left[\tilde{\mathcal{Q}}(l, r) \geq \mathcal{Q}(l, r) + 2\varepsilon \log n \|F\| \right] \\ &= Pr \left[\mathcal{Q}(l, r) + \tilde{\mathcal{Q}}(l, r) - \mathcal{Q}(l, r) \geq \mathcal{Q}(l, r) + 2\varepsilon \log n \|F\| \right] \\ &= Pr \left[\tilde{\mathcal{Q}}(l, r) - \mathcal{Q}(l, r) \geq 2\varepsilon \log n \|F\| \right] \\ &\leq \left(\frac{E[\tilde{\mathcal{Q}}(l, r) - \mathcal{Q}(l, r)]}{2\varepsilon \log n \|F\|} \right)^r \\ &= \left(\frac{2 \frac{\varepsilon}{e} \log n}{2\varepsilon \log n \|F\|} \right)^r = \left(\frac{1}{e} \right)^r < \left(\frac{1}{2} \right)^r = \delta \end{aligned}$$

da cui segue la tesi.

Problema 13

Elementi distinti

Problema. *Progettare e analizzare un algoritmo di data streaming che permetta di approssimare il numero di elementi distinti.*

Problema 14

Cuckoo hashing

Problema. *Scrivere tutti i passaggi dell'analisi del costo dell'inserimento di un elemento in una tabella di cuckoo hashing. Discutere anche della cancellazione e della sua complessità.*

Dobbiamo fare hashing da un insieme di n elementi ad un insieme di r elementi. Invece di procedere nel modo classico usando le liste di adiacenza (che nel caso pessimo potrebbero contenere tutti gli elementi), vogliamo un modo che ci permetta di avere esattamente un elemento in associato ad ognuno degli r valori (quindi che sia possibile salvare gli n elementi su un array di dimensione r). Per farlo, ci avvaliamo di due funzioni hash, 2-wise indipendenti, $h_1(x)$ e $h_2(x)$, in questo modo:

Algoritmo 2 Inserimento in Cuckoo hashing

- 1: provo ad inserire x in $h_1(x)$
 - 2: se la cella è libera lo inserisco semplicemente
 - 3: se la cella non è libera tolgo l'elemento y dalla cella $h_1(x)$ e ripeto il procedimento per y , provando a inserirlo in $h_1(y)$ se $h_1(x) = h_2(y)$ o in $h_2(y)$ se $h_1(x) = h_1(y)$, per un massimo di n volte.
 - 4: se il valore non è stato ancora inserito si cambiano le funzioni di hashing, e si riprova ad inserire il valore che si stava cercando di inserire alla n -esima iterazione.
-

Si nota, come vedremo, che il numero di iterazioni massimo nel punto 3 serve per evitare di andare in loop quando si tenta di inserire un valore.

Per fare l'analisi è necessario introdurre i concetti di grafo Cuckoo e di bucket, più un lemma:

Definizione (Grafo Cuckoo). *Il grafo Cuckoo è un grafo che ha per nodi le celle dell'array, con un arco uscente in ogni cella contenente un valore, che punta alla cella alternativa secondo le funzioni $h_1(x)$, $h_2(x)$. Ovvero, se il nodo i contiene il valore x , i avrà un arco uscente verso $h_2(x)$ se $i = h_1(x)$ o viceversa un arco verso $h_1(x)$ se $i = h_2(x)$.*

Definizione (Bucket). *Si dice bucket di un valore x l'insieme dei nodi raggiungibili dai nodi $\{h_1(x), h_2(x)\}$ nel grafo Cuckoo. Ossia tutti i nodi con cui potremmo avere a che fare nel caso volessimo inserire x .*

Lemma 7. Per ogni nodo i e j , e ogni $c > 1$, se $r \geq 2cn$, la probabilità che esista un cammino tra i e j di lunghezza l è al più $\frac{c^{-l}}{r} = \frac{1}{c^l r}$. Ovvero, se il numero di celle nell'array è sufficientemente più grande del numero di valori salvati, la probabilità che esista un cammino di lunghezza l tra due nodi è $O(\frac{1}{r})$, e decresce esponenzialmente.

Dimostrazione. Procediamo per induzione sulla lunghezza del percorso:

- per $l = 1$: un percorso di lunghezza 1 tra due nodi i e j esiste sse per qualche x $h_1(x) = i \wedge h_2(x) = j$ oppure $h_1(x) = j \wedge h_2(x) = i$, si ha:

$$\begin{aligned} & Pr[(h_1(x) = i \wedge h_2(x) = j) \vee (h_1(x) = j \wedge h_2(x) = i)] = \\ & = Pr[h_1(x) = i \wedge h_2(x) = j] + Pr[h_1(x) = j \wedge h_2(x) = i] = \\ & = 2Pr[h_1(x) = i] Pr[h_2(x) = j] = \\ & = 2 \frac{1}{r} \frac{1}{r} = \frac{2}{r^2} \end{aligned}$$

Siccome il numero di elementi per cui vale la proprietà vista sopra è al più n , si ha:

$$\begin{aligned} & Pr[\exists \text{ percorso di lunghezza 1 tra } i \text{ e } j] \\ & \leq n \frac{2}{r^2} = \frac{2n}{r} \frac{1}{r} \\ & \left\{ r \geq 2cn \text{ per ipotesi} \Rightarrow c \leq \frac{r}{2n} \Rightarrow \frac{1}{c} \geq \frac{2n}{r} \right\} \\ & \leq \frac{1}{cr} = \frac{c^{-1}}{r} \end{aligned}$$

- per $l > 1$ è necessario che:
 1. Esista un percorso ottimo lungo $l - 1$ da i a k .
 2. Esista un arco tra k e j .

Abbiamo

$$Pr[(1)] = \frac{c^{1-l}}{r}$$

per ipotesi induttiva. Inoltre, usando lo stesso ragionamento di prima otteniamo che

$$Pr[(2)] = \frac{c^{-1}}{r}.$$

Notiamo che i valori possibili di k sono r e che quindi la probabilità totale è data da:

$$r Pr[(1)] Pr[(2)] = r \frac{c^{-l}}{r^2} = \frac{c^{-l}}{r}$$

□

La probabilità che al punto 3 dell'inserimento avvenga un reashing, è maggiorata dalla probabilità che per qualche elemento esista un ciclo. Se notiamo che *esiste un ciclo di lunghezza $l \Leftrightarrow$ esiste un percorso di lunghezza l tra i e i* otteniamo:

$$\begin{aligned}
& Pr [\exists \text{un ciclo per il nodo } i \text{ nel grafo Cuckoo}] \\
&= \sum_{l=1}^{\infty} Pr [\exists \text{ciclo di lunghezza } l \text{ nel grafo Cuckoo}] \\
&= \sum_{l=1}^{\infty} Pr [\exists \text{percorso di lunghezza } l \text{ tra } i \text{ e } i] \\
&\leq \sum_{l=1}^{\infty} \frac{c^{-l}}{r} = \frac{1}{r(c-1)}
\end{aligned}$$

da cui:

$$\begin{aligned}
& Pr [\text{rehashing}] \\
&= \sum_{i=1}^r Pr [\exists \text{un ciclo per il nodo } i \text{ nel grafo cuckoo}] \\
&= r * \frac{1}{r(c-1)} = \frac{1}{c-1}
\end{aligned}$$

Ponendo $c = 3$ la probabilità di un rehash è $\frac{1}{2}$, e di n rehash è $\frac{1}{2^n}$, quindi il numero atteso di rehash ad ogni inserimento è

$$\sum_{i=1}^n i * \frac{1}{2^i} = 2.$$

Il costo medio di un inserimento quindi è dato dal costo di due rehashing, ognuno da $\Theta(n)$, quindi a sua volta $\Theta(n)$, mentre il costo ammortizzato per ogni inserimento è $O(1)$.

La cancellazione avviene in $O(1)$, cercando il valore da cancellare nelle sole due celle possibili ed eliminandolo, è possibile osservare infatti che la struttura che si ottiene è ancora un cuckoo hashing dove la funzione $h_1(x)$ è quella che mette tutti gli elementi esattamente dove sono e la funzione $h_2(x)$ è una qualunque (o varianti equivalenti).

Problema 15

Random search tree

Problema. *Scrivere l'algoritmo per inserire una chiave in un random search tree con una sola discesa dalla radice (i.e., senza dover risalire poi dalla foglia appena inserita verso la radice mediante le rotazioni).*

L'algoritmo per l'inserimento è il seguente:

Algoritmo 3 Inserimento in un albero random di ricerca binario

```
1: function INSERT( $x, T$ )
2:    $n \leftarrow T.size$ 
3:    $r \leftarrow random(0, n)$ 
4:   if  $r == n$  then
5:      $insert\_root(x, T)$ 
6:   if  $x < T.key$  then
7:      $insert(x, T.left)$ 
8:   else
9:      $insert(x, T.right)$ 
```

a questo punto si pone il problema di inserire l'elemento nel sottoalbero che lo dovrà contenere in modo da mantenere l'integrità della struttura, per fare questo usiamo il seguente algoritmo, che separa gli elementi più piccoli di x e quelli più grandi di x , e al posto del sottoalbero di partenza mette un sottoalbero con radice x , figlio sinistro il sottoalbero contenente tutti valori più piccoli di x e figlio destro contenente tutti quelli più grandi:

Algoritmo 4 Inserimento nella radice di un sottoalbero

```
1: function INSERT_ROOT( $x, T$ )
2:   rbintree  $S, G$ 
3:   split( $x, T, \&S, \&G$ )
4:    $T \leftarrow \text{new\_node}()$ 
5:    $T.\text{left} = S, T.\text{right} = G$ 
6:   return  $T$ 
7: function SPLIT( $x, T, L, R$ )
8:   if empty( $T$ ) then
9:      $*L \leftarrow \text{empty\_tree}(), *R \leftarrow \text{empty\_tree}()$ 
10:    return
11:   if  $x < T.\text{key}$  then
12:      $*R \leftarrow T$ 
13:     split( $x, T.\text{left}, L, \&(*R.\text{left})$ )
14:   else
15:      $*L \leftarrow T$ 
16:     split( $x, T.\text{right}, \&(*L.\text{right}), R$ )
17:   return
```

Problema 16

Lista invertita compressa

Problema. Prendiamo una sequenza ordinata crescente di n interi i_1, i_2, \dots, i_n , come per esempio una lista invertita. La rappresentazione compressa differenziale è la sequenza S di $|S|$ bit ottenuti concatenando $\gamma(i_1), \gamma(i_2 - i_1), \dots, \gamma(i_n - i_{n-1})$, dove $\gamma(x)$ rappresenta il gamma code di Elias per la codifica dell'intero $x \geq 1$ in $2\lfloor \log_2 x \rfloor + 1$ bit. Mostrare come aggiungere un'opportuna directory di spazio $O(|S|)$ bit (meglio ancora, di $o(|S|)$ bit) per poter accedere velocemente, dato $j \in [2 \dots n]$, alla codifica $\gamma(i_j - i_{j-1})$. Estendere tale approccio per accedere velocemente a i_j (e quindi poter eseguire una ricerca binaria sugli interi della lista invertita compressa).

Problema 17

Prefix tree del codice di Huffman

Problema. *Impostare un algoritmo per costruire il prefix tree del codice di Huffman. Dimostrare l'ottimalità di tale albero in termini di numero di bit utilizzati per codici prefix free dei simboli.*

Problema 18

Applicazioni di LZ77

Problema. *Sfruttando le caratteristiche dell'algoritmo LZ77 di Lempel e Ziv per suddividere un testo in una sequenza di frasi, mostrare come utilizzare LZ77 per*

- (a) nascondere dei bit all'interno del file compresso risultante,*
- (b) trovare la più lunga sottostringa che si ripete, ossia che appare almeno due volte nel testo.*

Problema 19

Dizionario di LZ78

Problema. *Progettare una struttura dati per memorizzare e interrogare velocemente il dizionario delle frasi ottenute incrementalmente con l'algoritmo LZ78. Valutare il costo delle soluzioni proposte.*